

Czym jest *web scraping* oraz *inżynieria wsteczna*?

Web Scraping

Web scraping to technika automatycznego pobierania i ekstrakcji danych ze stron internetowych. Proces ten polega na analizie struktury HTML strony i wydobywaniu z niej interesujących informacji, takich jak teksty, obrazy, tabele czy linki.

Zastosowania web scrapingu

- Monitorowanie cen konkurencji w e-commerce
- Agregacja danych z różnych źródeł
- Zbieranie informacji do analiz rynkowych
- Tworzenie baz danych kontaktów
- Automatyzacja procesów biznesowych

Narzędzia i technologie

Do web scrapingu wykorzystuje się różne narzędzia, takie jak:

- BeautifulSoup (Python)
- Scrapy (Python)
- Puppeteer (JavaScript)
- Selenium (różne języki)

Inżynieria Wsteczna API

Inżynieria wsteczna (reverse engineering) w kontekście interfejsów API to proces analizowania i odkrywania sposobu działania niedokumentowanych lub słabo

udokumentowanych API. Polega na badaniu requestów HTTP, analizie odpowiedzi serwera oraz zrozumieniu logiki komunikacji między klientem a serwerem.

Proces inżynierii wstecznej API

1. Przechwytywanie ruchu sieciowego za pomocą narzędzi takich jak Chrome DevTools, Burp Suite czy Wireshark
2. Analiza requestów HTTP/HTTPS - metody, nagłówki, parametry, ciała zapytań
3. Identyfikacja endpointów API i ich funkcjonalności
4. Badanie mechanizmów uwierzytelniania i autoryzacji
5. Dokumentowanie odkrytych wzorców i struktur danych
6. Testowanie i weryfikacja działania API

Narzędzia do reverse engineeringu API

- Chrome DevTools / Firefox Developer Tools
- Postman / Insomnia
- Burp Suite
- mitmproxy
- Fiddler

Web Scraping vs Reverse Engineering API

Główne różnice między tymi podejściami:

Aspekt	Web Scraping	Reverse Engineering API
Źródło danych	HTML/CSS strony internetowej	Endpointy API (JSON/XML)
Stabilność	Niska - zmiana struktury HTML wymaga aktualizacji	Wyższa - API zazwyczaj bardziej stabilne
Wydajność	Wolniejsza - pobieranie całych stron	Szybsza - tylko potrzebne dane
Złożoność	Zależy od struktury HTML	Wymaga analizy ruchu

		sieciowego
Obciążenie serwera	Wyższe	Niższe

Aspekty Prawne i Etyczne

Zarówno web scraping, jak i inżynieria wsteczna API mogą wiązać się z kwestiami prawnymi i etycznymi. Należy zawsze sprawdzić:

- Regulamin serwisu (Terms of Service)
- Plik robots.txt
- Obowiązujące przepisy prawne (np. RODO w UE)
- Prawa autorskie do danych
- Limity częstotliwości zapytań, aby nie obciążać nadmiernie serwerów

Najlepsze Praktyki

- Respektowanie robots.txt i polityki serwisu
- Implementacja opóźnień między requestami
- Używanie user-agentów identyfikujących bota
- Cache'owanie danych, aby minimalizować liczbę zapytań
- Monitorowanie zmian w strukturze API/HTML
- Obsługa błędów i mechanizmów rate limiting